

Relazione al progetto

I Parte

Test di Uniformità

Il gruppo ha deciso di sottoporre ad un Test di Uniformità (basato sulla statistica *Chi-Quadro*) il generatore di *Lehmer* con moltiplicatore e modulo rispettivamente $(a, m) = (48271, 2^{31} - 1)$.

Note Teoriche sul test

Il test si basa sulla suddivisione dell'intervallo $(0,1)$ (sul quale opera il generatore di *Lehmer*) in k bins, sulla generazione di n chiamate a *random()* e il conseguente conteggio di osservazioni che cadono all'interno del bin x -esimo ($\forall x \in \{0, 1, \dots, k-1\}$).

Indichiamo con:

$o[x] :=$ "il numero di osservazioni che cadono nel bin x -esimo";

$e[x] :=$ "il numero atteso di osservazioni che cadono nel bin x -esimo quando esse sono realizzazioni di variabili aleatorie $U(0,1)$ (ossia $e[x] = n/k$)".

Ebbene, quando il campione è un insieme fatto di realizzazioni di variabili aleatorie indipendenti e $U(0,1)$ e quando n/k è sufficientemente grande ($n/k \geq 10$) si dimostra che la seguente statistica tende ad una variabile aleatoria *Chi-Quadro*($k-1$):

$$v = \sum_{x=0}^{k-1} \frac{(o[x] - n/k)^2}{n/k}$$

Intuitivamente, quando *random()* genera effettivamente realizzazioni di variabili aleatorie $U(0,1)$ la quantità al numeratore tende ad essere piccola (poiché $o[x]$ tende ad n/k). Sotto questa ipotesi tutta la statistica v tende ad essere piccola. Per questo motivo, fissato un livello di confidenza $(1-\alpha)$ con α solitamente pari a 0.05 , e posti v_1^* e v_2^* :

$v_1^* = \text{idfChisquare}(k-1, \alpha/2)$ e $v_2^* = \text{idfChisquare}(k-1, 1 - \alpha/2)$, ovvero i quantili della *Chi-Quadro*($k-1$) rispettivamente di ordine $\alpha/2$ e $1 - \alpha/2$

Allora:

$$\Pr(v_1^* \leq v \leq v_2^*) = 1 - \alpha$$

Per questo motivo si asserisce che se la statistica v è tale per cui $v > v_2^*$ o $v < v_1^*$ allora il test fallisce: questo accade evidentemente con probabilità α (di solito 0.05) se la densità è effettivamente $U(0,1)$.

In effetti, come verrà illustrato nel seguito della trattazione, per testare l'uniformità del generatore sotto esame verranno prodotte s statistiche, una per ogni *stream* messo a disposizione dal generatore di *Lehmer* della libreria *rngs* (in tutto 256 streams). In caso di uniformità ci si aspetta il fallimento del test da parte di $s \cdot \alpha$ ($256 \cdot 0.05 \approx 13$) statistiche: qualora ci si discostasse troppo da questo valore (per eccesso o per difetto) si solleverebbero profondi dubbi sull'uniformità del generatore.

Motivazioni di impiego del test e relativi punti di forza e debolezza

Certamente il primo test da sottoporre ad un generatore è il test di uniformità. Esso svolge un ruolo essenziale per l'identificazione di tutte le implementazioni non corrette già dal punto di vista della *flatness*. Tuttavia l'aver superato il test in questione da parte di un generatore non implica la sua bontà: ad esempio questo test non tiene affatto conto dell'ordine con il quale sono riempiti i *bins*. Per questo motivo viene detto test di randomicità statisticamente *debole*.

Codice

L'implementazione del test è stata sviluppata in linguaggio C, utilizzando le librerie *rngs* (generatore di *Lehmer multistream*) e *rvms* (quantili *Chi-Quadro*). Di seguito il codice nel file *chisquare.c*:

```
#include <stdio.h>
#include <stdlib.h>
#include <math.h>
#include "rngs.h"
#include "rvms.h"

#define K 1000          /*It is the number of bin (K >= 1000)*/
#define N 10000         /*It is the number of variate for STREAM (N >= 10*K)*/
#define ALFA 0.05       /*Level of confidence of Chi-Square test*/
#define STREAMS 256     /*Considered STREAMS*/

double chiSquareByStream(int index){
/*Return the Chi-Square statistic based on N variates selected by STREAM
index*/

    double expected = (N/K);
    double statistic = 0;

    int o[K];
    int x;
    int i;

    for(x = 0 ; x < K ; x++){
        o[x] = 0;
    }

    SelectStream(index);

    for(i = 0 ; i < N ; i++){
        x = floor((Random())*K);
        o[x]++;
    }

    for(x = 0 ; x < K ; x++){
        statistic = statistic + (double)(pow((o[x] - expected) , 2)) /
(expected);
    }

    return statistic;
}
```

```

double* chiSquare(){
/*Return all 256 Chi-Square statistics, one for STREAM*/
    double* V = (double*)malloc(STREAMS*sizeof(double));

    if(V==NULL) {
        perror("Error in malloc\n");
        exit(1);
    }

    int i;

    for(i = 0 ; i < STREAMS ; i++)
        V[i] = 0;

    for(i = 0 ; i < STREAMS ; i++)
        V[i] = chiSquareByStream(i);

    return V;
}

double computeV1(void){
/*Return idfChiSquare( $K - 1$ ,  $ALFA / 2$ )*/

    return idfChiSquare((long)(K - 1), (double)(ALFA / 2));
}

double computeV2(void){
/*Return idfChiSquare( $K - 1$ ,  $1 - ALFA / 2$ )*/

    return idfChiSquare((long)(K - 1), (double)(1 - (ALFA / 2)));
}

void destroy(double* v){
/*Free heap*/

    free(v);
}

int writeData(void){
/*Write results of chiSquare() on data.txt*/

    FILE* fd;
    int i;

    fd = fopen("data.txt", "a");

    if(fd==NULL) {
        perror("Error opening file");
        exit(1);
    }

    double* V = chiSquare();

    for(i = 0 ; i < STREAMS ; i++)
        fprintf(fd, "%0.2f,", V[i]);

```

```

        fprintf(fd, "%0.2f,", computeV1());
        fprintf(fd, "%0.2f", computeV2());

        destroy(V);
        fclose(fd);

        return 0;
}

int main(void)
{
    int i = writeData();

    if(i != 0)
        return EXIT_FAILURE;
    else
        return EXIT_SUCCESS;
}

```

Il numero di *bin* è impostato a 1000 e dunque per rendere la statistica utilizzabile n è impostato a 10.000 ($n/k \geq 10$). L'algoritmo costruisce un array di 256 statistiche (una per *stream*), salvate successivamente nel file *data.txt* nel formato *stat_0*, *stat_1*, ... , *stat_255* appendendo infine i due quantili v_1^* e v_2^* .

Visualizzazione dello *scatter plot* e conclusioni

I dati scritti sul file *data.txt* sono utilizzati dall'applicazione statistica *R* per visualizzare su uno *scatter plot* tutte le 256 statistiche ottenute e verificare il superamento o meno del test da parte del generatore di *Lehmer* $(a, m) = (48271, 2^{31} - 1)$. Nella pagina successiva è inserita l'immagine dello *scatter plot* ottenuto. Sulle ascisse vi è il numero dello *stream* considerato e sulle ordinate il valore della statistica ottenuta dal test di uniformità sul generatore associato. Le linee orizzontali che corrispondono rispettivamente ai punti sulle ordinate di valore circa 913.3 e 1088.5 rappresentano i quantili della *Chi-Quadro* v_1^* e v_2^* . È evidente che vi sono 8 punti minori del quantile v_1^* (troppa uniformità) e 6 punti maggiori del quantile v_2^* (assenza di uniformità). Dunque il test di uniformità in tutto fallisce 14 volte: tuttavia era stato precedentemente asserito che in caso di uniformità da parte del generatore ci si aspettasse che circa $s \cdot \alpha$ (in questo caso 13) statistiche fallissero. Per questo motivo possiamo concludere che il generatore in questione supera positivamente il test di uniformità.

K = 1000
N = 10000

